Operaciones de aprendizaje automático (Gpo 10)

Período: Trimestral Sep - Dic de 2026

Actividad Individual | Código de experimentación base con MLFlow

Saul Salgado Ortega

1 Proceso de experimentación y repositorio

Convertí el entrenamiento del notebook en funciones ejecutables. El dataset UCI 409 contiene 60 registros; predigo *Total orders* de la siguiente observación de negocio con el día de semana y demandas anteriores. Para las filas 25-48, reajusto el pipeline solo con el historial previo. Excluyo los componentes A+B+C contemporáneos porque suman la respuesta.

El repositorio organiza la copia de datos en **data/**, la lógica en **src/**, la exploración en **notebooks/**, la comparación y el servidor en **scripts/**, las pruebas en **tests/** y las evidencias en **docs/**. **train.py** expone la ejecución; README y GUIA_EXPLICADA explican su uso. MLproject y python_env.yaml añaden la entrada de MLflow Projects.

GitHub público:
https://github.com/Drezneck-RM/tc5061-mlflow-experimentacion

2 Ejecución y seguimiento con MLflow

Desde la raíz del repositorio, con Python 3.13 y las versiones de requirements.txt instaladas, ejecuto los siguientes comandos. Cambiar los argumentos crea una corrida nueva:

python train.py --n-estimators 100 --max-depth 1 --min-samples-leaf 2 --seed 42

python scripts/run_comparison.py --output-dir results/entrega-final --evaluate-best-test

python scripts/start_mlflow.py

La comparación genera seis configuraciones, una repetición y la evaluación descriptiva de la seleccionada. Al repetirla, uso una carpeta nueva para conservar la evidencia. Sin argumentos, train.py usa 100 árboles, profundidad 3, hoja mínima 2 y semilla 42; --help describe las opciones.

3 Registro comparación y reproducibilidad

Cada corrida registra hiperparámetros, semilla, MAE, RMSE, predicciones, gráfica y modelo. En **http://127.0.0.1:5001** abro **TC5061_Experimentacion_CLI_Demanda**, selecciono las seis corridas en **Runs** y pulso **Compare**. Ordeno validation_mae de menor a mayor; **Artifacts** permite revisar los archivos y **Models** el modelo guardado. Las figuras A1-A3 muestran estas evidencias.

Fijo semilla 42 en Python, NumPy y Random Forest, versiones en requirements.txt y hashes de datos y código. La repetición de la base igualó parámetros, métricas y predicciones con tolerancia 1e-12; la recarga del modelo conservó su predicción. Se verificó repetibilidad en el entorno probado.

4 Análisis de resultados

Comparé seis configuraciones sobre los mismos 24 pronósticos, cambiando un hiperparámetro a la vez. La selección utiliza el menor MAE de validación; la repetición de control queda fuera de la tabla. MAE y RMSE están en unidades originales de demanda.

Configuración	Árboles	Prof.	Hoja	MAE	RMSE
depth_1	**100**	**1**	**2**	**65.84**	**93.91**
leaf_4	100	3	4	71.34	101.13
trees_300	300	3	2	74.20	102.96
base	100	3	2	77.13	106.18
depth_6	100	6	2	77.27	106.02
leaf_1	100	3	1	86.34	115.46

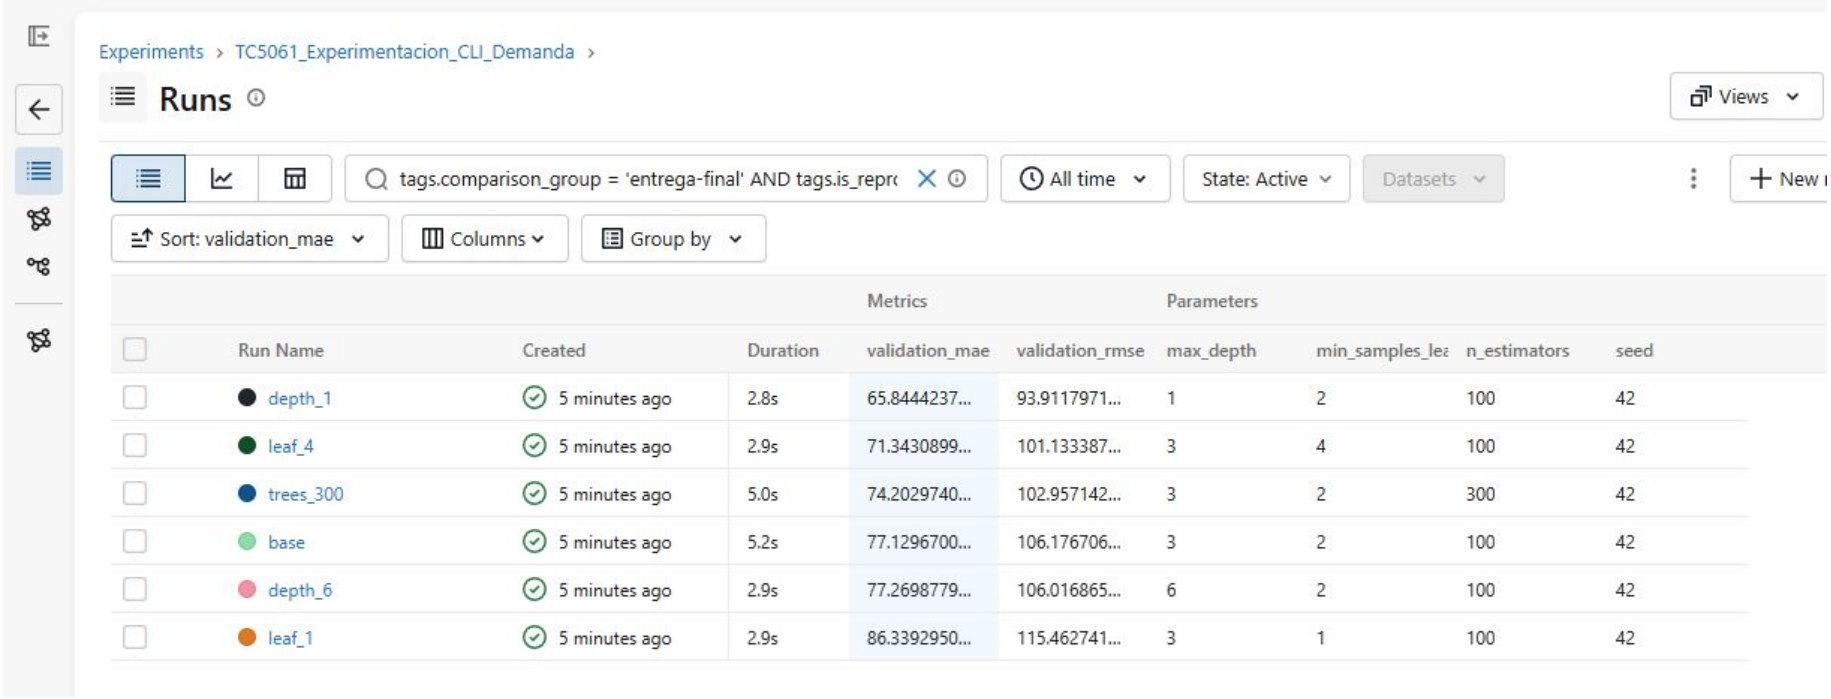
Mejor configuración. depth_1 obtuvo MAE 65.84 y RMSE 93.91: redujo el MAE 11.49% frente a Dummy (74.39). Reducir la profundidad de 3 a 1 produjo la mayor variación probada: 11.29 unidades menos que la base. Reducir la hoja de 2 a 1 empeoró 9.21; aumentar de 100 a 300 árboles mejoró 2.93. Esto favorece limitar la complejidad en esta muestra, sin demostrar un óptimo global ni interacciones.

Límites. En las 12 filas finales, ya examinadas antes, el MAE del seleccionado fue 52.92 frente a 50.13 de Dummy: 5.57% peor. Ese bloque es descriptivo y no cambió la selección. La validación usada para ajustar tampoco es una prueba independiente. Faltan fechas completas, unidades físicas confirmadas y más datos. El proceso es auditable; la ventaja predictiva no es estable y requiere evaluación futura.

Anexo Capturas de pantalla

Figura A1. *Tabla comparativa de corridas en MLflow*

Seis configuraciones del experimento TC5061_Experimentacion_CLI_Demanda. La tabla muestra los hiperparámetros y los errores de validación; la configuración depth_1 tiene el menor MAE.

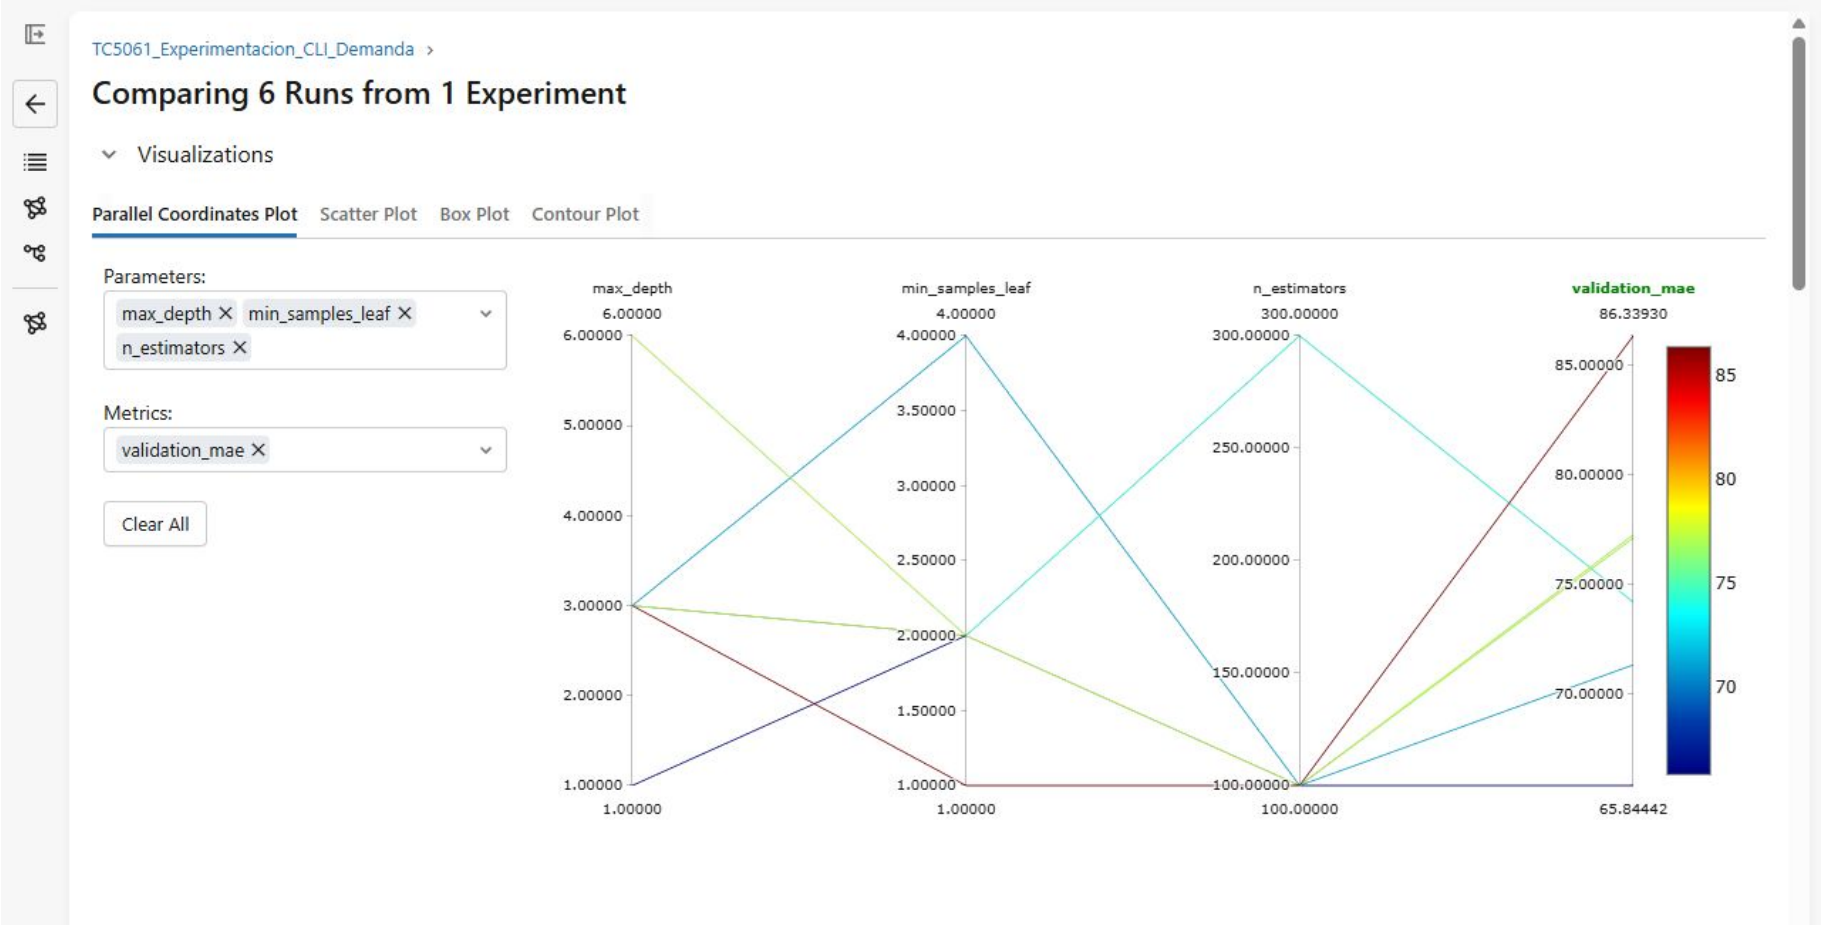


Filtro de la entrega: tags.comparison_group = 'entrega-final' AND tags.is_reproducibility_repeat = 'false'.

Anexo Capturas de pantalla

Figura A2. *Comparación visual de las seis configuraciones*

La vista Compare relaciona los valores de los hiperparámetros con los errores registrados. Cada línea representa una configuración evaluada en los mismos orígenes de pronóstico.

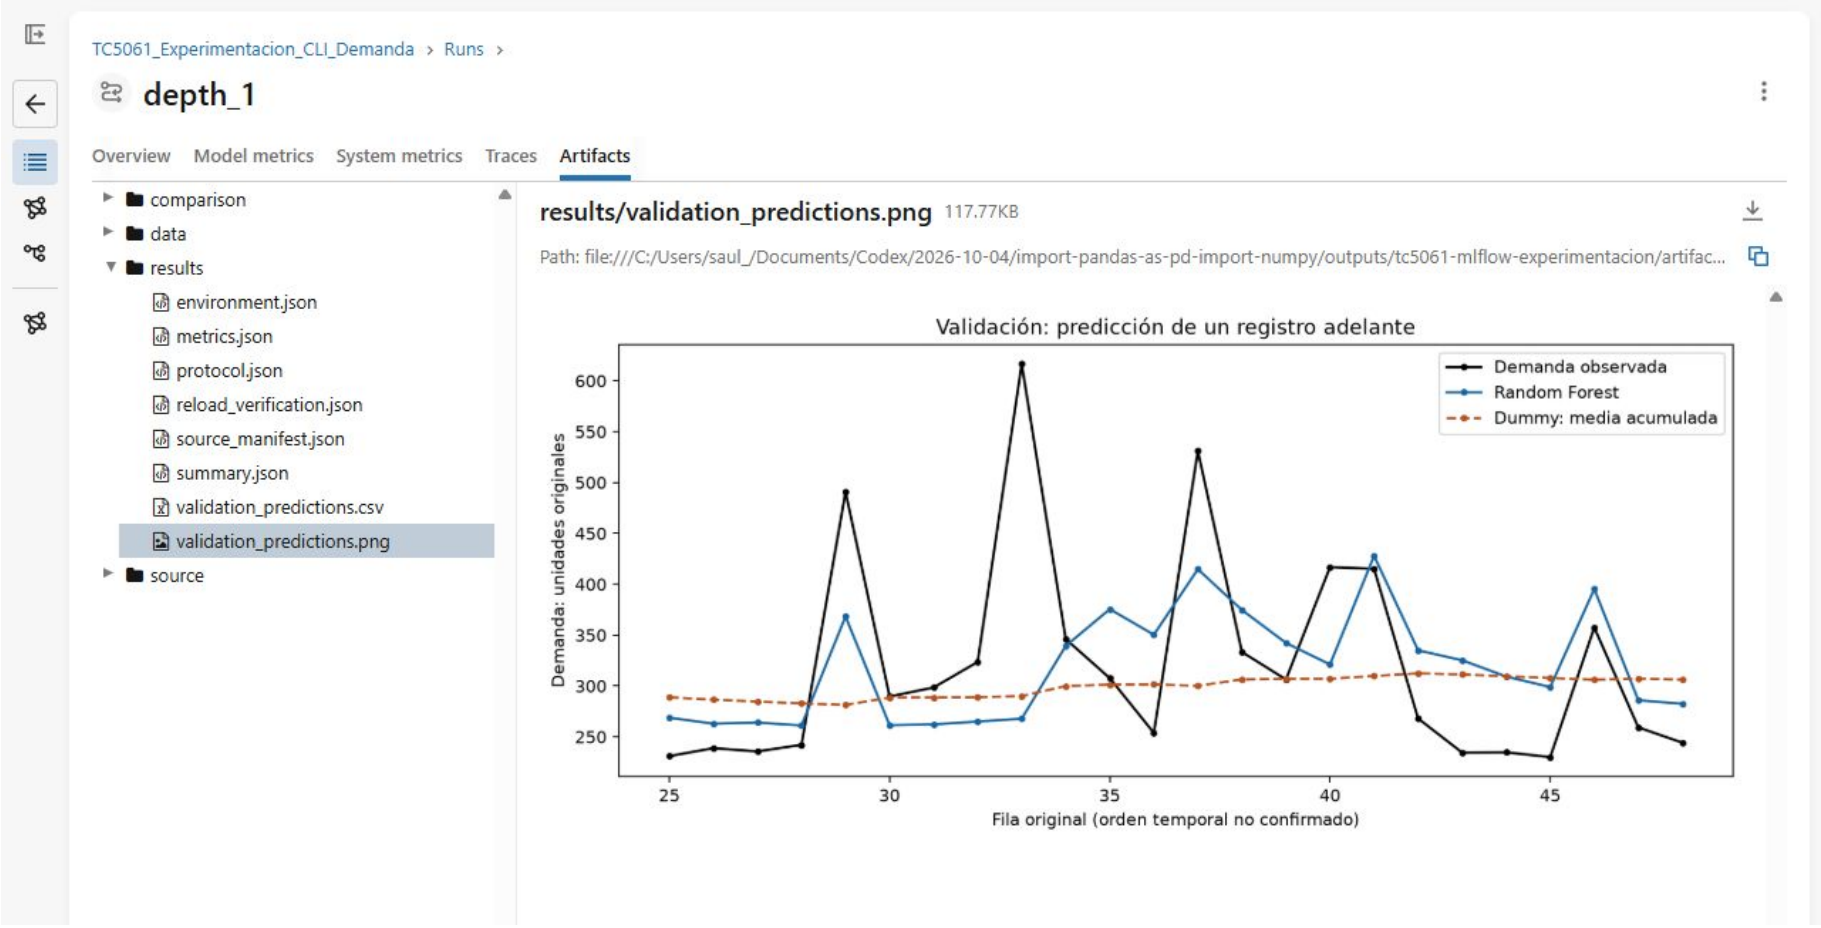


La evaluación es progresiva: después de cada pronóstico se incorpora la demanda observada para el siguiente.

Anexo Capturas de pantalla

Figura A3. *Detalle y artefactos de la corrida seleccionada*

La corrida depth_1 conserva predicciones, gráfica y archivos de verificación. El modelo guardado corresponde al ajuste hasta la fila 48; las métricas de validación resumen los 24 reajustes previos.



Corrida seleccionada: 613f6c1c9395459391b7a27914d4de64. Su recarga reprodujo la predicción verificada.